Regresión Lineal Simple

Carolina Sanchez

2026-04-30

Cargamos librearías

```
library(readxl)
library(ggplot2)
library(dplyr)
library(gridExtra) # Forma de organizar los gráficos.
library(GGally)
library(corrplot)
library(car) # qqPlot de los residuales.
library(lmtest) # Prueba de autocorrelación de DW y prueba de Breusch-Pagan
library(nortest) # Prueba de KS
library(MASS)
library(caTools) # sample.split
library(tseries) #Prueba de Jarque Bera
```

Cargamos la base de datos

```
library(readxl)
Pulso <- read_excel("~/CURSOS ANALISIS DE DATOS/AXM/R/CLASE 6/PulsoCardiacoMujeres (1).xlsx")
head(Pulso)
```

```
## # A tibble: 6 × 5
##    Edad Estatura  Peso Cintura Pulso
##   <dbl>    <dbl> <dbl>   <dbl> <dbl>
## 1    17     1.63  51.7    67.2    76
## 2    32     1.69  67.2    82.5    72
## 3    25     1.58  48.5    66.7    88
## 4    55     1.58  72      93      60
## 5    27     1.51  57.2    82.6    72
## 6    29     1.62  55.4    75.4    68
```

Análisis Exploratorio

Verificamos si tenemos la presencia de valores NA

```
colSums(is.na(Pulso)) # No hay presencia de valores NA
```

```
##     Edad Estatura     Peso  Cintura    Pulso
##        0        0        0        0        0
```

Realizamos un resumen de estadísticas descriptivas de la variable de interés.

```
summary(Pulso$Cintura)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   66.70   73.42   81.95   85.03   94.38  126.50
```

- La mediana del contorno de la cintura es menor que la media, lo que sugiere una asimetría a la derecha.
- El 25% de las mujeres de la muestra tienen una cintura mayor que 94.38
- Existe una gran diferencia del contorno de la cintura entre el valor mínimo y el valor máximo.

Realizamos un boxplot y análisis de ouliers

```
boxplot(Pulso$Cintura) # No hay presencia de outliers en la variable de interés.
```

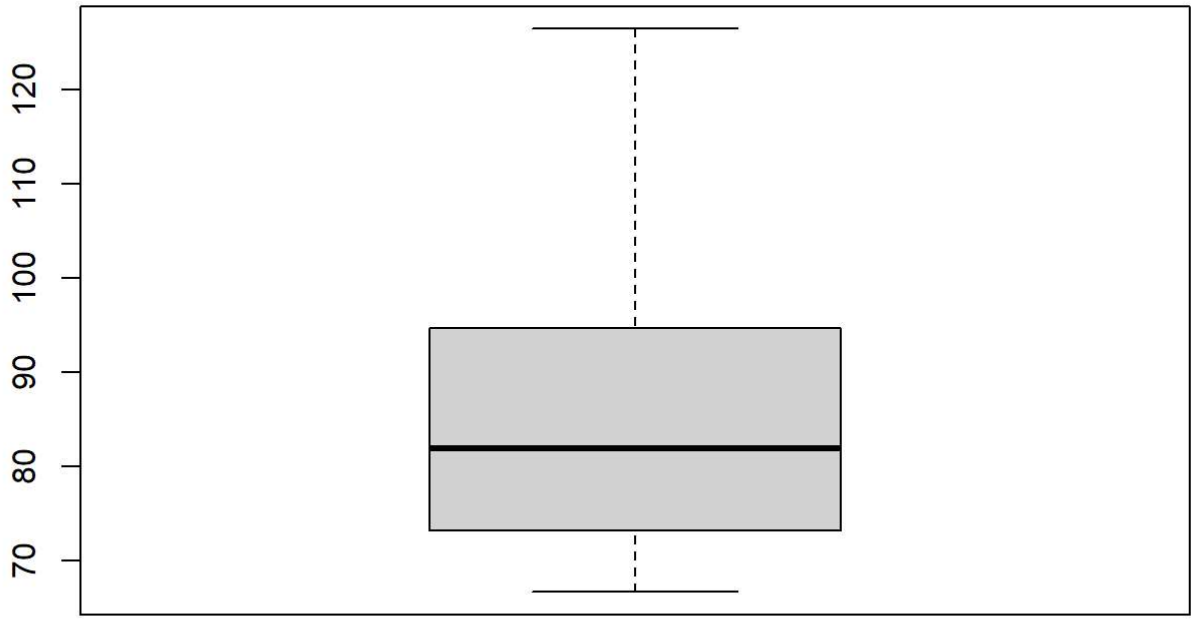


```
boxplot.stats(Pulso$Cintura)
```

```
## $stats
## [1]  66.70  73.25  81.95  94.75 126.50
##
## $n
## [1] 40
##
## $conf
## [1] 76.57887 87.32113
##
## $out
## numeric(0)
```

- Tenemos el valor del bigote inferior = 66.70 que coincide con el valor mínimo de los datos.
- Tenemos el valor del bigote superior = 126.50 que coincide con el valor máximo de los datos.
- No hay presencia de outliers en los datos.

Matriz de correlaciones

```
matriz_corr <- cor(select_if(Pulso, is.numeric))
matriz_corr
```

```
##               Edad  Estatura      Peso   Cintura     Pulso
## Edad     1.0000000 0.1167019 0.5630050 0.6594466 0.3079243
## Estatura 0.1167019 1.0000000 0.3610981 0.1887012 0.2079803
## Peso     0.5630050 0.3610981 1.0000000 0.9210571 0.1434836
## Cintura  0.6594466 0.1887012 0.9210571 1.0000000 0.1327250
## Pulso    0.3079243 0.2079803 0.1434836 0.1327250 1.0000000
```

Diagrama de calor para ver la matriz de correlaciones.

```
corrplot(matriz_corr, method = "color", addCoef.col = "black")
```

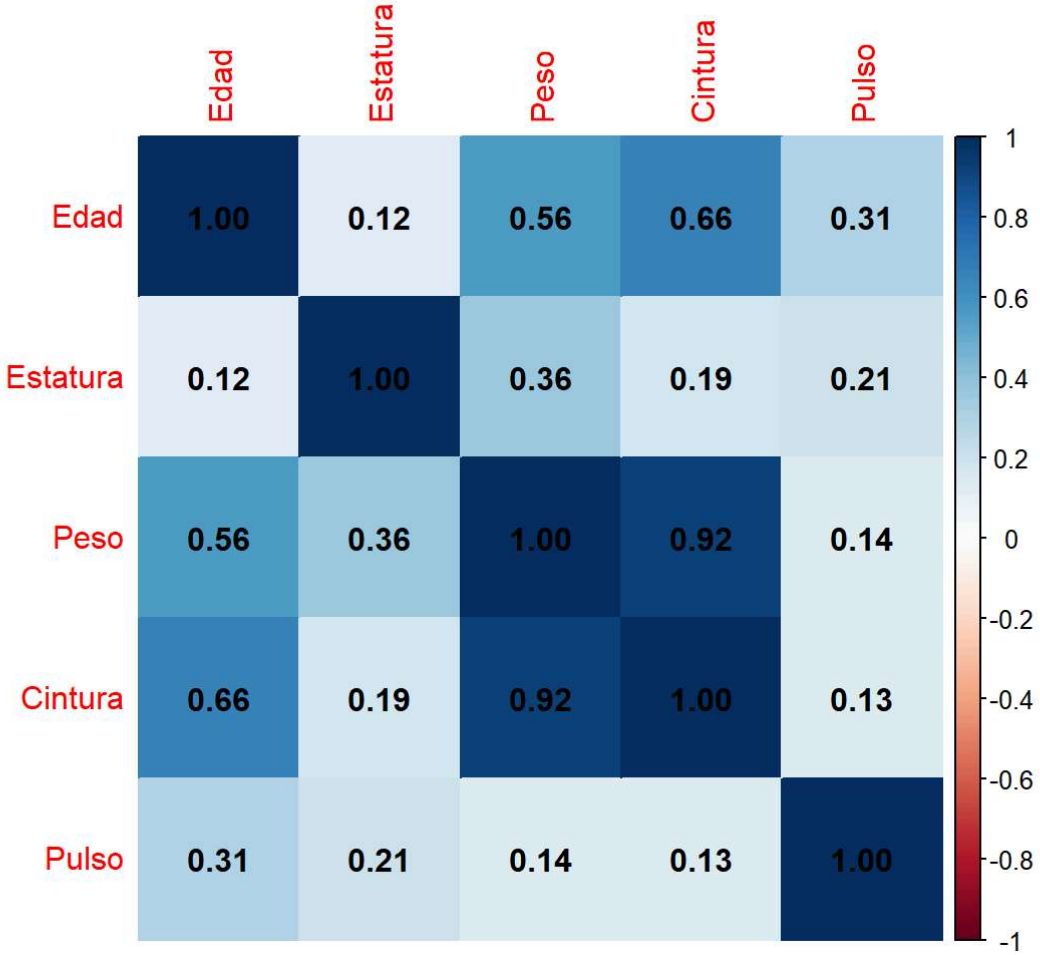

- Tenemos una correlación positiva muy fuerte entre la cintura y el peso de una mujer.
- Tenemos una correlación positiva moderada entre las variables Peso - Edad y Cintura - Edad.
- Tenemos una correlación positiva debil entre las demás variables.

Matriz de gráficos de dispersión

```
pairs(Pulso, main = "Matriz de gráficos de dispersión", pch = 20, col =  "purple", lwd = 3)
```

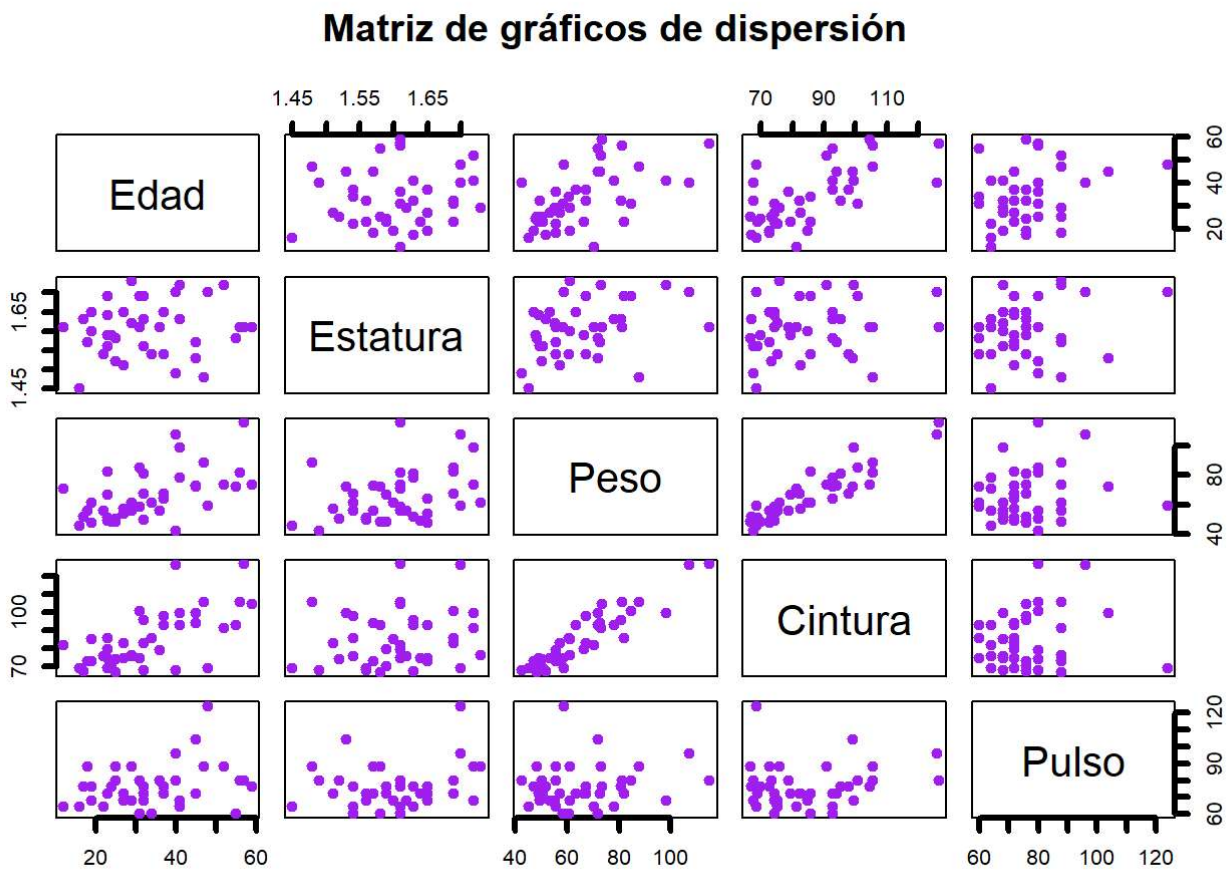


```
# Es clara la correlación positiva entre el peso y la cintura de una mujer.
```

- Se observa una relación directamente lineal entre la cintura y el peso.

Histogramas para cada variable

```
variables <- c("Edad", "Estatura", "Peso", "Cintura", "Pulso")

# Configura una ventana de gráficos (ajusta según el número de variables)
par(mfrow = c(3, 2))  # 3 filas, 2 columnas (ajustable)

# Recorremos cada variable para graficarla
for (var in variables) {
  datos <- Pulso[[var]]
  hist(datos, probability = TRUE, main = paste("Distribución de", var), xlab = var, col = "purpl
e", breaks = nclass.Sturges(datos))
  lines(density(datos), col = "black", lwd = 3)
  curve(dnorm(x, mean = mean(datos), sd = sd(datos)), add = TRUE, col = "grey", lwd = 3)
}
```

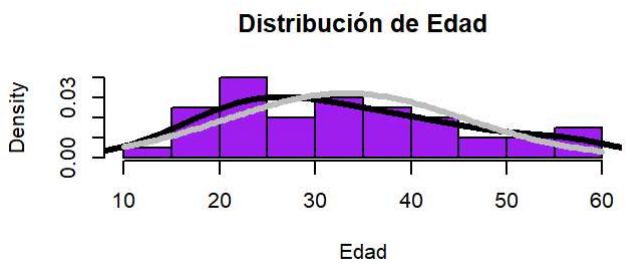

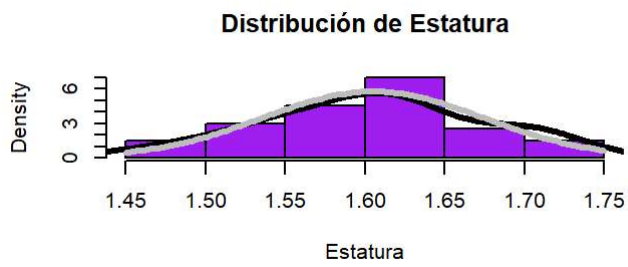

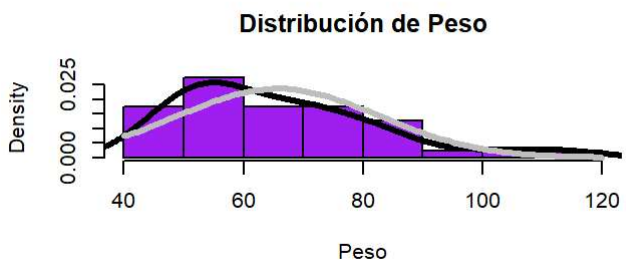

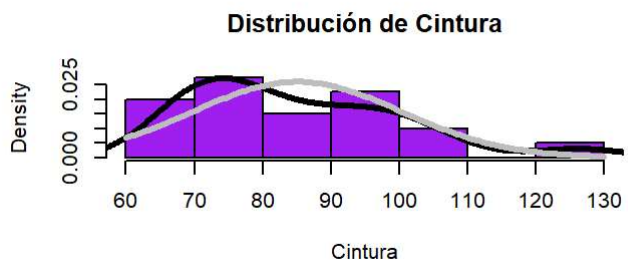

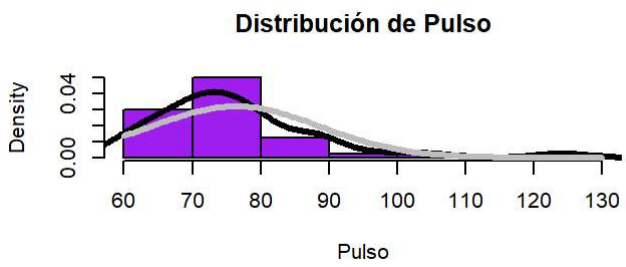

Aplicación del Modelo

Seleccionamos como nuestra variable de respuesta a “Peso” y nuestra variable predictora a “Cintura”

Dividir nuestros datos en datos de entrenamiento y datos de prueba.

```
set.seed(42)

# Barajeamos la base de datos
barajeo <- slice_sample(Pulso, prop = 1)

# Dividimos aleatoriamente los datos
split <- sample.split(barajeo$Edad, SplitRatio = 0.8) # Vector lógico

# Base de entrenamiento
train <- subset(barajeo, split == TRUE)

# Base de Prueba o Testeo
test <- subset(barajeo, split == FALSE)
```

Ajustamos el modelo con los datos de entrenamiento

```
modelo <- lm(Peso ~ Cintura, data = train)
summary(modelo)
```

```
##
## Call:
## lm(formula = Peso ~ Cintura, data = train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -12.5478  -5.1178   0.2585   3.6588  17.7889
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -17.50199    7.08877  -2.469   0.0195 *
## Cintura       0.98806    0.07996  12.358 2.67e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.145 on 30 degrees of freedom
## Multiple R-squared:  0.8358, Adjusted R-squared:  0.8303
## F-statistic: 152.7 on 1 and 30 DF,  p-value: 2.669e-13
```

El modelo ajustado es:

$$\hat{Peso} = -13.44328 + 0.90873 * Cintura$$

Elementos del Modelo:

test Fisher:

En regresión simple, el test F se utiliza para probar si el modelo con la variable explicativa es significativamente mejor que un modelo que solo incluye la media. El juego de hipótesis que se plantea es:

$$H_0 : \beta_1 = 0$$
$$H_1 : \beta_1 \neq 0$$

- En el test de Fisher tenemos un p-value: 2.669e-13 < 0.05 se rechaza la hipótesis nula en favor de la alternativa.

- Existe suficiente evidencia estadística para sustentar la aseveración de que al menos una beta es diferente de cero.

Coeficientes:

- El p-valor de la variable “Cintura” y el intercepto son menores que el nivel de significancia, indicando que son significativas para el modelo.
- Intersección (Intercept) = -17.50199: Cuando la variable Cintura = 0, el modelo predice que el peso sería aproximadamente -17.50199 kg. Esta interpretación no tiene sentido práctico, ya que una cintura de 0 cm no es realista. Sin embargo, el intercepto es necesario para calcular los valores ajustados.
- Pendiente (Cintura) = 0.98806: Por cada aumento de 1 cm en la cintura, el peso promedio aumenta en 0.98806 kg.

Residuales:

- La mediana de los residuos 0.2585 es cercana a 0, lo cual sugiere que el modelo no tiene un sesgo fuerte en la predicción ya que el error típico está cercano a cero.

- Aunque el modelo se ajusta bastante bien, hay algunos errores (residuos) un poco grandes.

R-squared

- El modelo explica el 83.58% de la variabilidad en el peso usando la cintura como predictor. Esto indica un ajuste fuerte.

```
# Gráfico de dispersión con línea de regresión
plot(train$Cintura, train$Peso, col='grey', pch = 16, xlab = "Cintura", ylab = "Peso", main = "R
egresión Lineal: Peso ~ Cintura", lwd = 5)
abline(modelo, col='purple', lwd = 2)
```

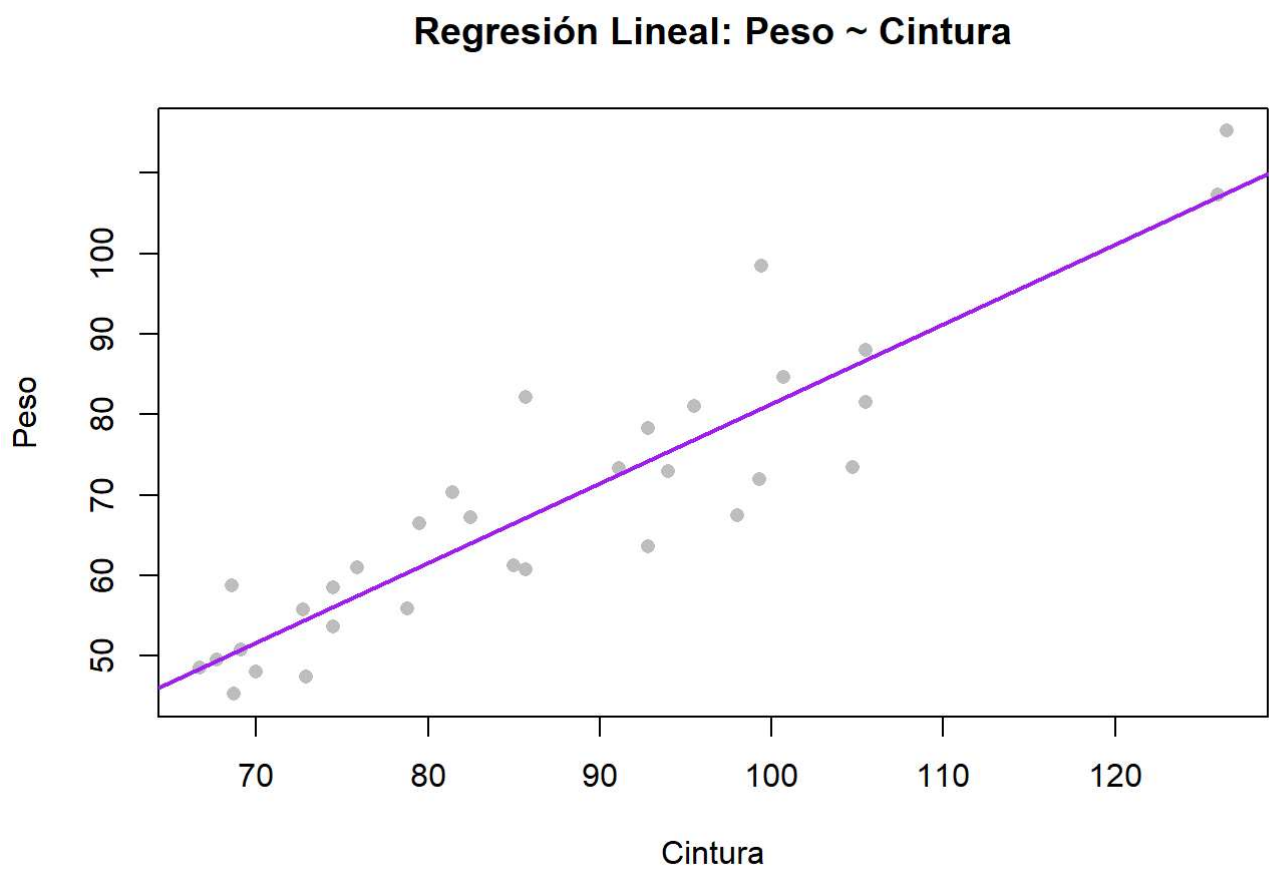

Verificamos supuestos de e

Pruebas de Normalidad

```
# Histograma de los residuales
hist(residuals(modelo), probability = T,col='purple', main='Histograma de residuos', breaks = nc
lass.Sturges(modelo$residuals))
lines(density(residuals(modelo)), col = "black", lwd = 3)
curve(dnorm(x, mean(residuals(modelo)), sd(residuals(modelo))), col = "grey", lwd = 3, add = T)
```

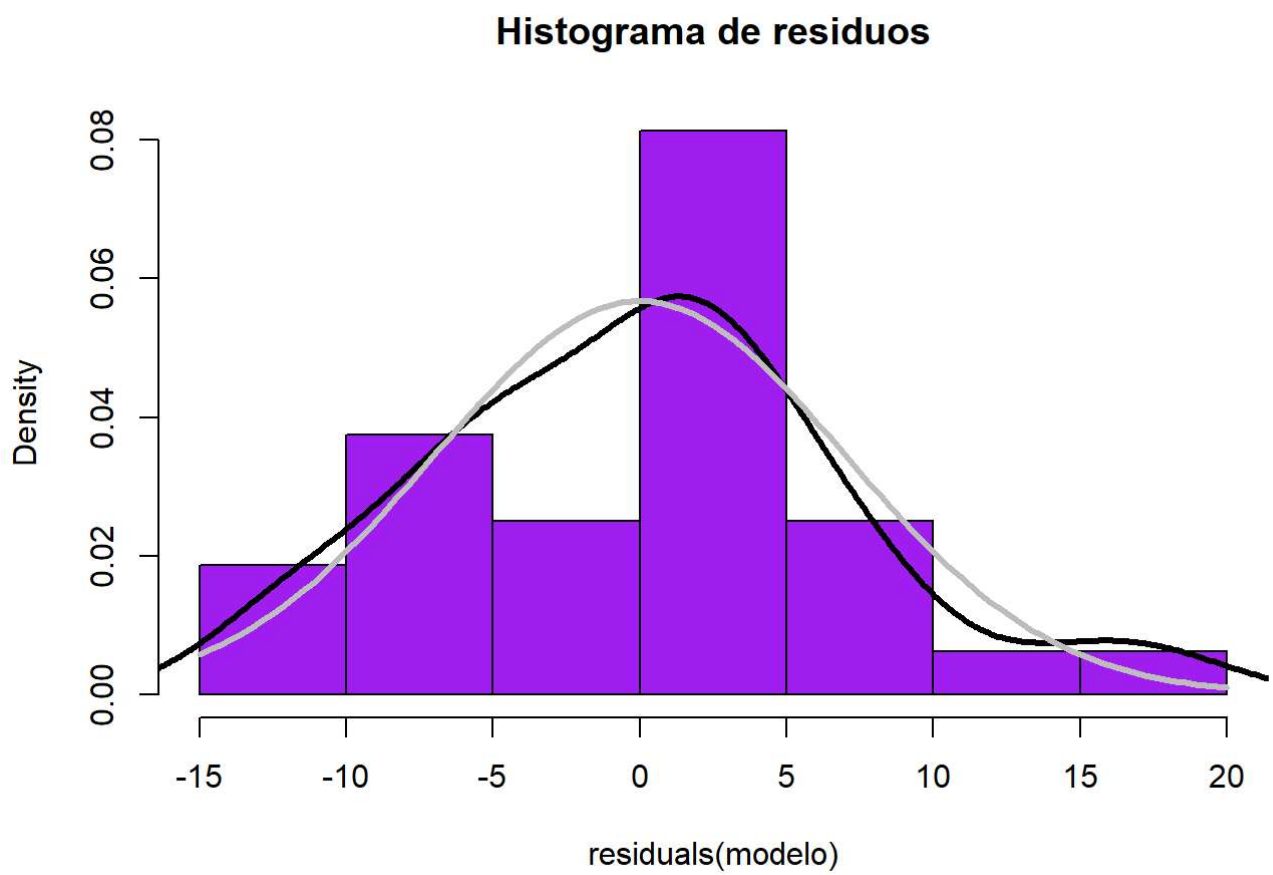


```
# QQ-NORM
qqPlot(residuals(modelo), pch = 20, col = "black", lwd = 2)
```

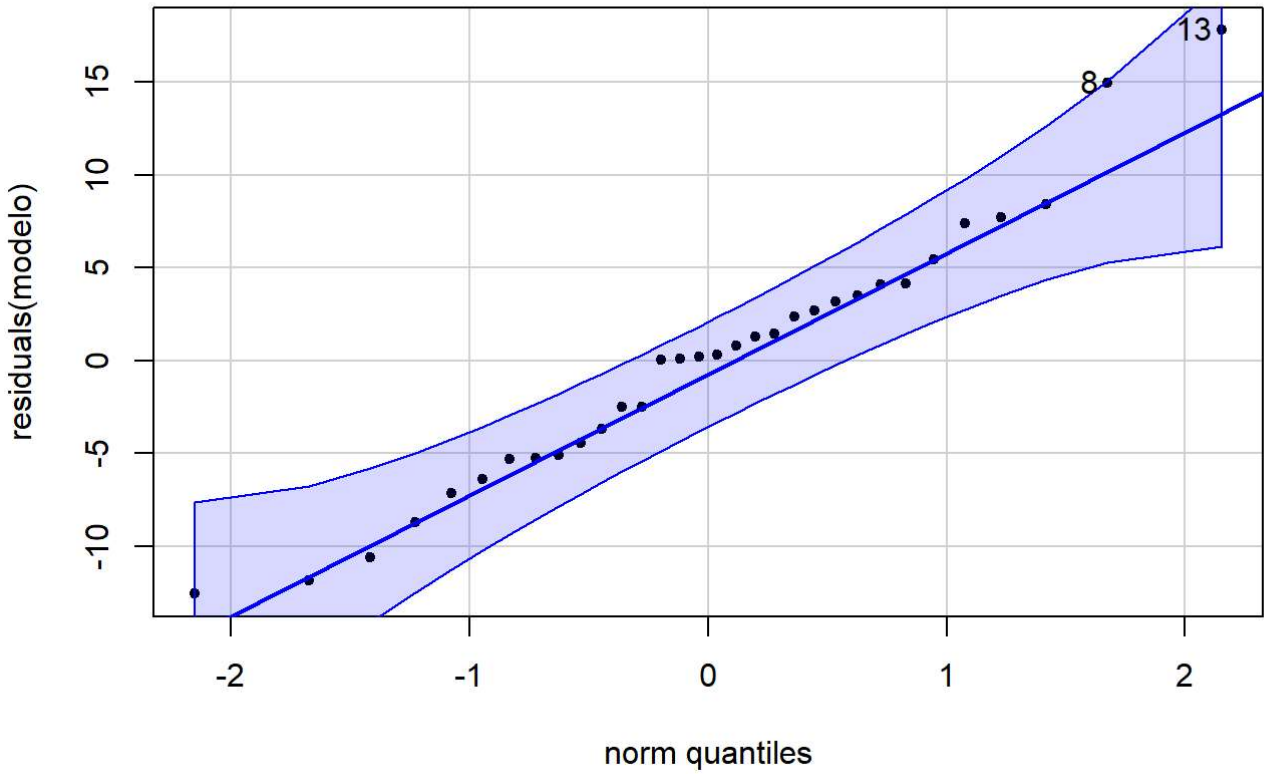


```
## [1] 13  8
```

```
# test de normalidad
shapiro.test(residuals(modelo)) # Si hay normalidad en los residuales.
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(modelo)
## W = 0.97392, p-value = 0.6137
```

- Como p-value = 0.6137 > 0.05 no se rechaza la hipótesis nula.
- Existe suficiente evidencia estadística para sustentar la aseveración de que los residuales siguen una distribución significativamente normal.

Homocedasticida (Igualdad de varianzas): La igualdad de varianzas se espera entre los residuos y los valores ajustados del modelo.

```
plot(fitted(modelo), residuals(modelo), col = 'grey', pch = 16, main = 'Fitted vs Residuals')
abline(h=0, col='purple')
```

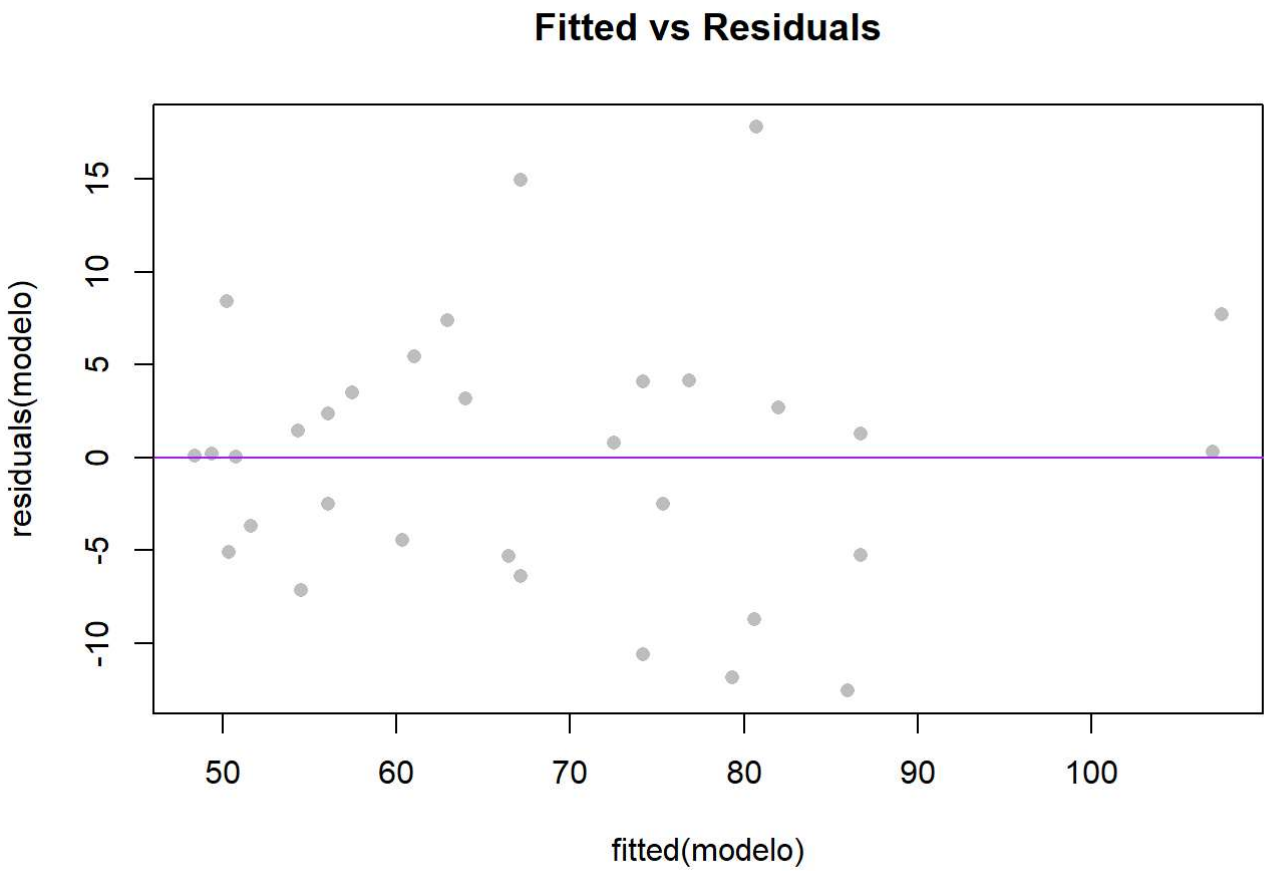


```
# fitted(modelo): Son los valores ajustados o predichos por tu modelo.
# residuals(modelo): Son los residuos.
```

- Como los puntos están dispersos de forma aleatoria arriba y abajo de la línea roja y no hay patrones se sugiere que si hay homocedasticidad.

La Prueba de **Breusch-Pagan** es una prueba estadística que se utiliza para detectar la heterocedasticidad en un modelo de regresión lineal. La heterocedasticidad ocurre cuando la varianza de los errores o residuos no es constante a lo largo de las observaciones, lo que violaría una de las suposiciones básicas de los modelos de regresión lineal (homocedasticidad).

H_0 : La varianza de los errores es constante (homocedasticidad) H_1 : La varianza de los errores no es constante (heterocedasticidad)

```
bptest(modelo)
```

```
##
##  studentized Breusch-Pagan test
##
## data:  modelo
## BP = 1.8447, df = 1, p-value = 0.1744
```

- Como p-value = 0.1744 > 0.05 no se rechaza la hipótesis nula.

- Existe suficiente evidencia estadística para sustentar la aseveración de que la varianza de los errores es constante.

El test de **Jarque Bera** es una prueba de normalidad que evalúa si una muestra de datos (en este caso, los residuos del modelo) tiene una asimetría (skewness) y una curtosis (kurtosis) cercanas a las de una distribución normal.

H_0 : Los residuos siguen una distribución normal (sin sesgo ni curtosis excesiva) H_1 : Los residuos no siguen una distribución normal (pueden tener sesgo y curtosis fuera de los parámetros normales)

```
jarque.bera.test(residuals(modelo))
```

```
##
##  Jarque Bera Test
##
## data:  residuals(modelo)
## X-squared = 0.85534, df = 2, p-value = 0.652
```

- Como p-value = 0.652 > 0.05 no se rechaza la hipótesis nula,
- Existe suficiente evidencia estadística para sustentar la aseveración de que los residuos siguen una distribución normal.

Uno de los supuestos del modelo de regresión lineal es que los residuos deben ser independientes entre sí.

La prueba de **Durbin-Watson** evalúa si existe autocorrelación de primer orden en los residuos del modelo de regresión, es decir, si los errores están correlacionados entre sí (especialmente entre un error y el anterior).

El estadístico de Durbin Watson toma valores entre 0 y 4:

- DW ≈ 2 → No hay autocorrelación
- DW < 2 → Autocorrelación positiva
- DW > 2 → Autocorrelación negativa

```
# Prueba de Durbin-Watson para autocorrelación de residuos
# H_0: No hay autocorrelación en los residuos (es decir, los residuos son independientes entre s
í).
# H_1: Sí hay autocorrelación en los residuos
dwtest(modelo)
```

```
##
##  Durbin-Watson test
##
## data:  modelo
## DW = 2.2082, p-value = 0.7528
## alternative hypothesis: true autocorrelation is greater than 0
```

- Como DW = 2.2082 lo cual está muy cerca de 2, entonces no hay evidencia de autocorrelación significativa. Esto indica que los errores del modelo son independientes.

Predicciones

```
# Predicciones en el conjunto de prueba
predicciones <- predict(modelo, newdata = test, interval = "confidence", level = 0.95)

# Guardar las predicciones y los intervalos de confianza en el conjunto de prueba
test$predicted <- predicciones[,1]
test$lower <- predicciones[,2]
test$upper <- predicciones[,3]

# Ver el conjunto de prueba con las nuevas columnas de predicciones
test
```

```
## # A tibble: 8 × 8
##    Edad Estatura  Peso Cintura Pulso predicted lower upper
##   <dbl>    <dbl> <dbl>   <dbl> <dbl>     <dbl> <dbl> <dbl>
## 1    17     1.63  51.7    67.2    76      48.9  44.7  53.1
## 2    25     1.52  50.3    73.6    80      55.2  51.8  58.6
## 3    55     1.58  72      93      60      74.4  71.6  77.1
## 4    27     1.51  57.2    82.6    72      64.1  61.4  66.8
## 5    40     1.49  42.4    67.8    80      49.5  45.4  53.6
## 6    22     1.54  55.9    75.5    64      57.1  53.9  60.3
## 7    29     1.62  55.4    75.4    68      57.0  53.8  60.2
## 8    23     1.64  49      74.5    72      56.1  52.8  59.4
```

Valores Influyentes

Columnas del output:

dfb.1_: Este valor muestra el cambio en el coeficiente estimado para la variable independiente “Cintura” si se elimina la observación en cuestión. Si es muy grande (por ejemplo, mayor que 1), puede indicar que esa observación tiene un efecto fuerte sobre el modelo.

dfb.Cntr: Similar al anterior, pero para el intercepto. Nos dice cómo cambia el intercepto del modelo si eliminamos la observación correspondiente.

dffit: Este valor es una medida de cuán “lejana” está una observación de la predicción ajustada para su valor. Un valor alto de dffit indica que esa observación puede estar alejándose de la relación general del modelo. Valores mayores a 2 o 3 suelen ser motivo de preocupación.

cov.r: Esta columna mide el cambio en la covarianza del modelo cuando se elimina una observación. Un valor cercano a 1 sugiere que la observación tiene un fuerte impacto en la covarianza.

cook.d: El estadístico de Cook (cook.d) es una medida que evalúa la influencia de una observación en el modelo de regresión en general. Básicamente, mide cuánto cambiarían los resultados del modelo si esa observación fuera eliminada. Si el valor de Cook es grande (generalmente mayor que 1), indica que esa observación tiene un gran impacto en los resultados del modelo y podría ser considerada influyente.

hat: La palanca (hat) mide cuán influyente es una observación en la predicción de su propio valor dentro del modelo. Si una observación tiene una palanca alta, significa que un pequeño cambio en esa observación podría afectar mucho su propia predicción, lo que indica que tiene un impacto considerable en cómo el modelo la interpreta. Esto también puede influir indirectamente en las predicciones de otras observaciones, ya que cambia la forma en que el modelo ajusta su estructura general.

```
# Evaluamos los valores influyentes
influencia <- influence.measures(modelo)

# Mostramos las medidas de influencia
summary(influencia)
```

```
## Potentially influential observations of
##   lm(formula = Peso ~ Cintura, data = train) :
##
##    dfb.1_ dfb.Cntr dffit cov.r   cook.d hat
## 8   0.11  -0.04     0.41  0.80_*  0.07   0.03
## 11 -0.02   0.02     0.03  1.37_*  0.00   0.22_*
## 13 -0.30   0.40     0.65  0.69_*  0.17   0.05
## 26 -0.56   0.62     0.66  1.24_*  0.22   0.22_*
```

```
# Para identificar puntos con alta influencia, se puede filtrar:
influencia$summaries[which(influencia$summaries$cook.d > 1),]
```

```
## NULL
```

Observación 8:

- cook.d = 0.80: Esto es un valor elevado. El estadístico de Cook mayor que 1 indica que la observación podría tener un gran impacto en la estimación del modelo.
- hat = 0.03: Esto indica que la observación no tiene una gran influencia en la predicción de su propio valor.

Observación 11:

cook.d = 1.37: Este es un valor significativamente mayor que 1, lo que sugiere que esta observación tiene un fuerte impacto en el modelo.

hat = 0.22: Este valor de “hat” es relativamente alto, lo que indica que esta observación tiene una gran influencia sobre las predicciones.

Observación 13:

- cook.d = 0.17: Este valor es bajo, lo que sugiere que esta observación no tiene una gran influencia en el modelo.
- hat = 0.05: Este valor también es bajo, lo que indica que la observación no tiene una gran influencia sobre la predicción de su propio valor.

Observación 26:

- cook.d = 1.24: Este valor es elevado, lo que sugiere que esta observación tiene una gran influencia en el modelo.
- hat = 0.22: Similar a la observación 11, esta observación tiene una alta influencia sobre las predicciones.

```
# Graficar influencia
plot(modelo, which = 4:5)
```

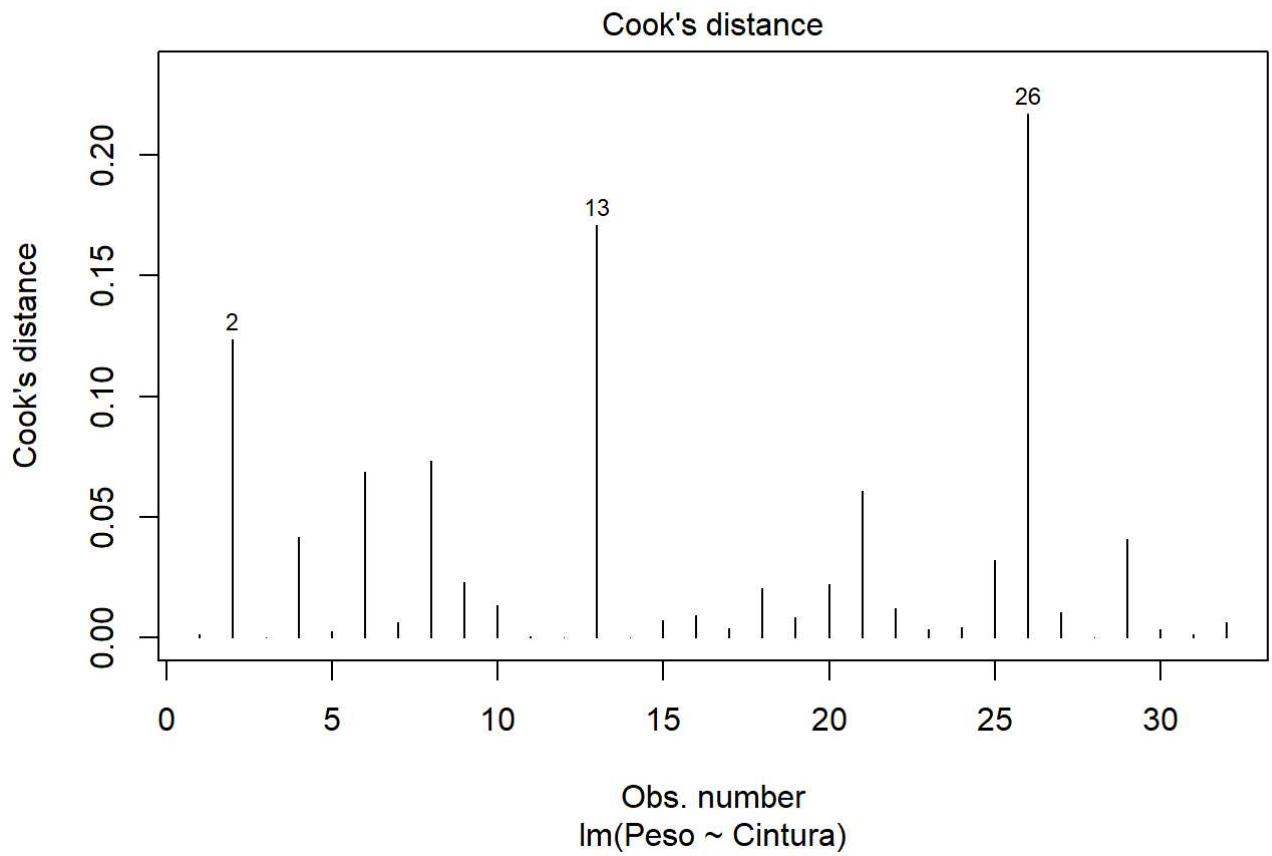
Cook's distance
Cook's distance
0.00
0.05
0.10
0.15
0.20
2
13
26
0
5
10
15
20
25
30
Obs. number
lm(Peso ~ Cintura)

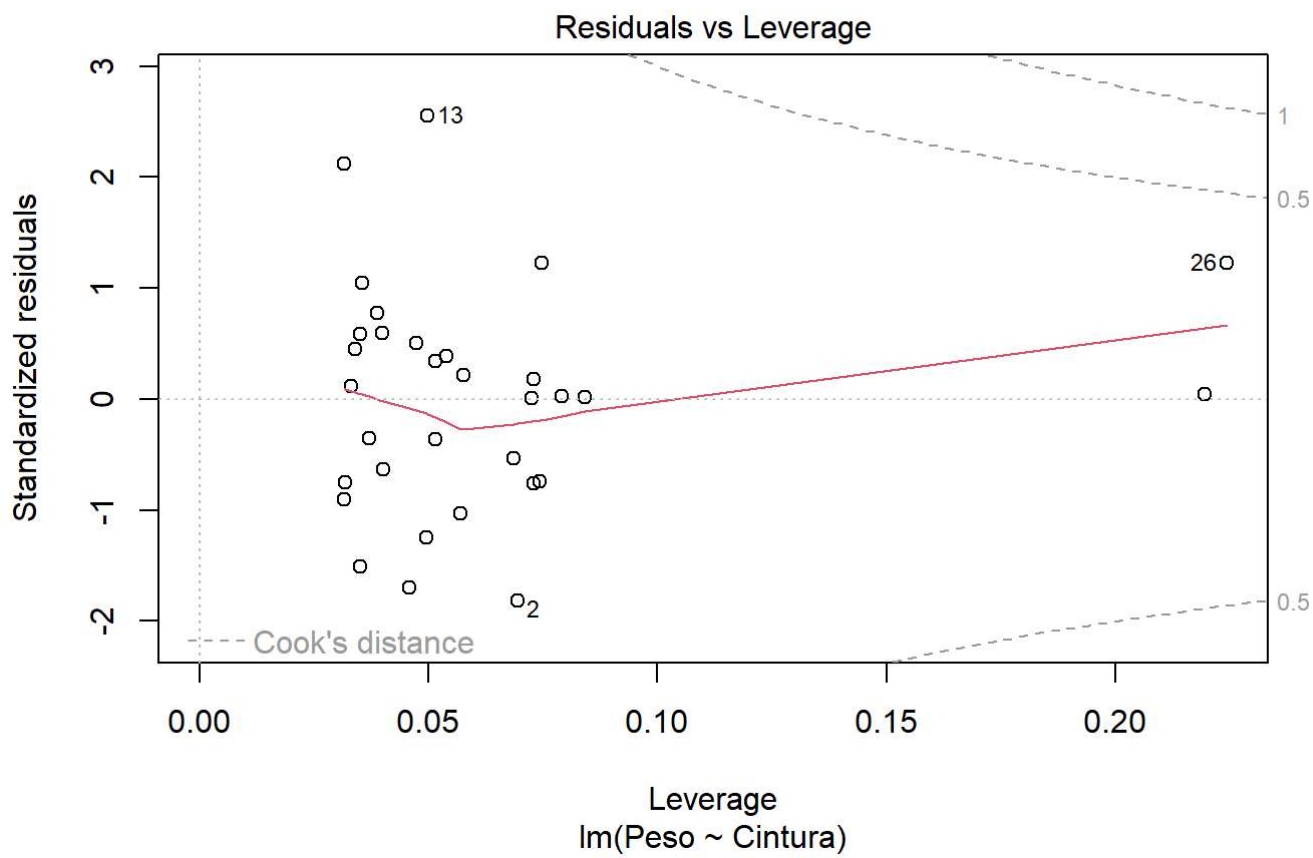
Residuals vs Leverage
Standardized residuals
3
2
1
0
-1
-2
13
26
2
1
0.5
0.5
Cook's distance
0.00
0.05
0.10
0.15
0.20
Leverage
lm(Peso ~ Cintura)

- La mayoría de los puntos están concentrados en el centro.
- El punto 26 tiene un leverage alto lo que puede estar influenciando mucho en la forma del modelo.
- El punto 2 y 13 tienen un residuo grande aunque con leverage bajo. Podríamos sugerir que el modelo no los predijo bien.

```
train[c(2,13,26),]
```

```
## # A tibble: 3 × 5
##    Edad Estatura  Peso Cintura Pulso
##   <dbl>    <dbl> <dbl>   <dbl> <dbl>
## 1    59     1.61  73.4   105.     76
## 2    41     1.72  98.5    99.4    68
## 3    57     1.61 115.    126.     80
```

#Modelo 2

Probamos el modelo sin la observación 26

```
train2 <- train[-26,]
```

Ajustamos el modelo con los datos de entrenamiento

```
modelo2 <- lm(Peso ~ Cintura, data = train2)
summary(modelo2)
```

```
##
## Call:
## lm(formula = Peso ~ Cintura, data = train2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -11.3836  -4.8204  -0.4341   3.4696  18.6940
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -13.54823    7.72056  -1.755   0.0899 .
## Cintura       0.93918    0.08857  10.603 1.72e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.083 on 29 degrees of freedom
## Multiple R-squared:  0.795,  Adjusted R-squared:  0.7879
## F-statistic: 112.4 on 1 and 29 DF,  p-value: 1.718e-11
```

El modelo ajustado es:

$$\hat{Peso} = -13.54823 + 0.93918 * Cintura$$

- La observación 26 era influyente ya que su presencia hacía que el intercepto fuera más bajo.
- El coeficiente de cintura cambió moderadamente, pero relevante si usas el modelo para predicciones.
- La observación 26 ayudaba a que el modelo explicara el 83.56% de la variabilidad y sin él baja al 79.5%.
- En conclusión, la observación 26 si es influyente ya que al quitarla el modelo cambia pero no se destruye y el ajuste sigue siendo bueno pero un poco menos explicativo.
- En el test de Fisher tenemos un p-value: 2.669e-13 < 0.05 se rechaza la hipótesis nula en favor de la alternativa. Es decir, tenemos al menos una beta diferente de cero.

```
# Gráfico de dispersión con línea de regresión
plot(train2$Cintura, train2$Peso, col='grey', pch = 16, xlab = "Cintura", ylab = "Peso", main =
"Regresión Lineal: Peso ~ Cintura", lwd = 5)
abline(modelo2, col='purple', lwd = 2)
```

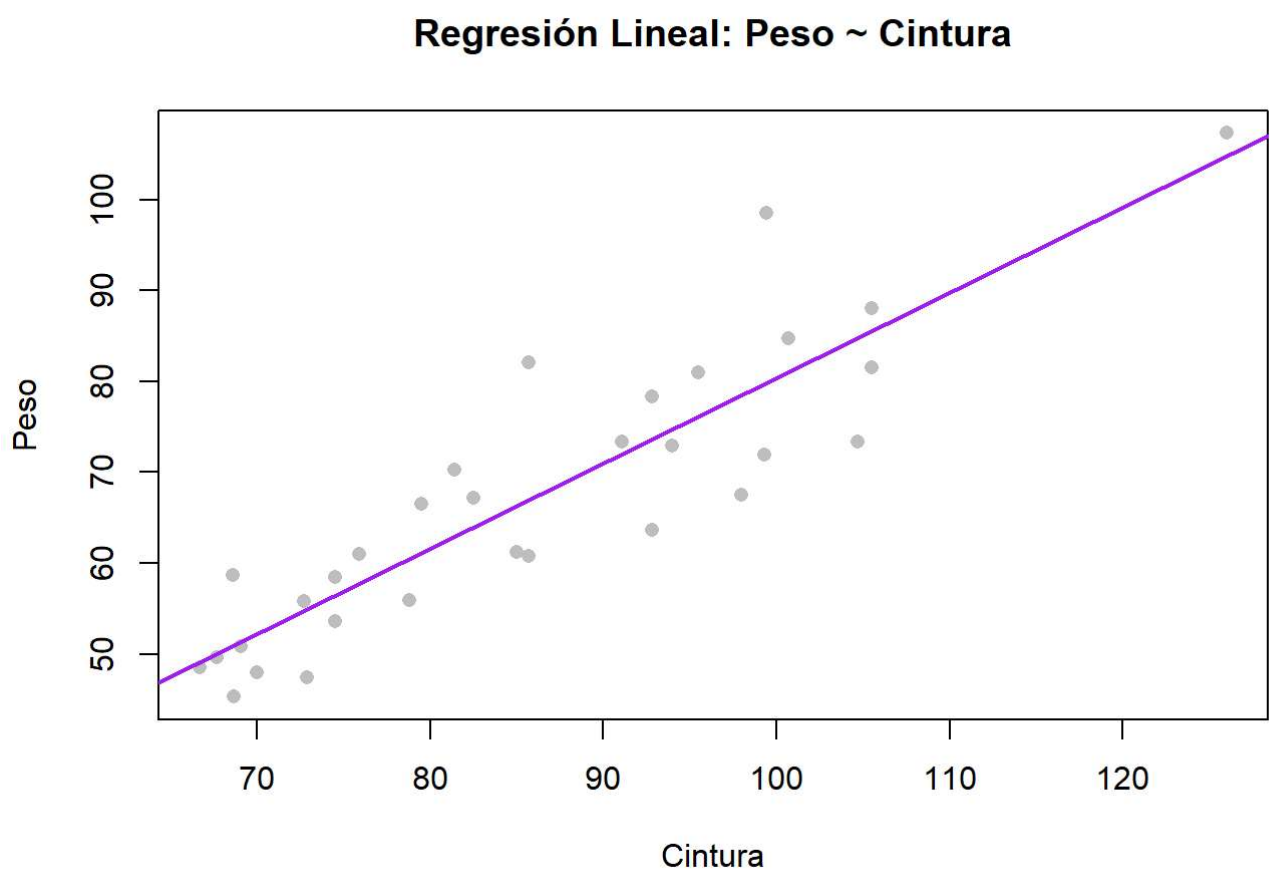

Verificamos supuestos de e

Pruebas de Normalidad

```
# Histograma de los residuales
hist(residuals(modelo2), probability = T,col='purple', main='Histograma de residuos', breaks = n
class.Sturges(modelo$residuals))
lines(density(residuals(modelo2)), col = "black", lwd = 3)
curve(dnorm(x, mean(residuals(modelo2)), sd(residuals(modelo2))), col = "grey", lwd = 3, add =
T)
```

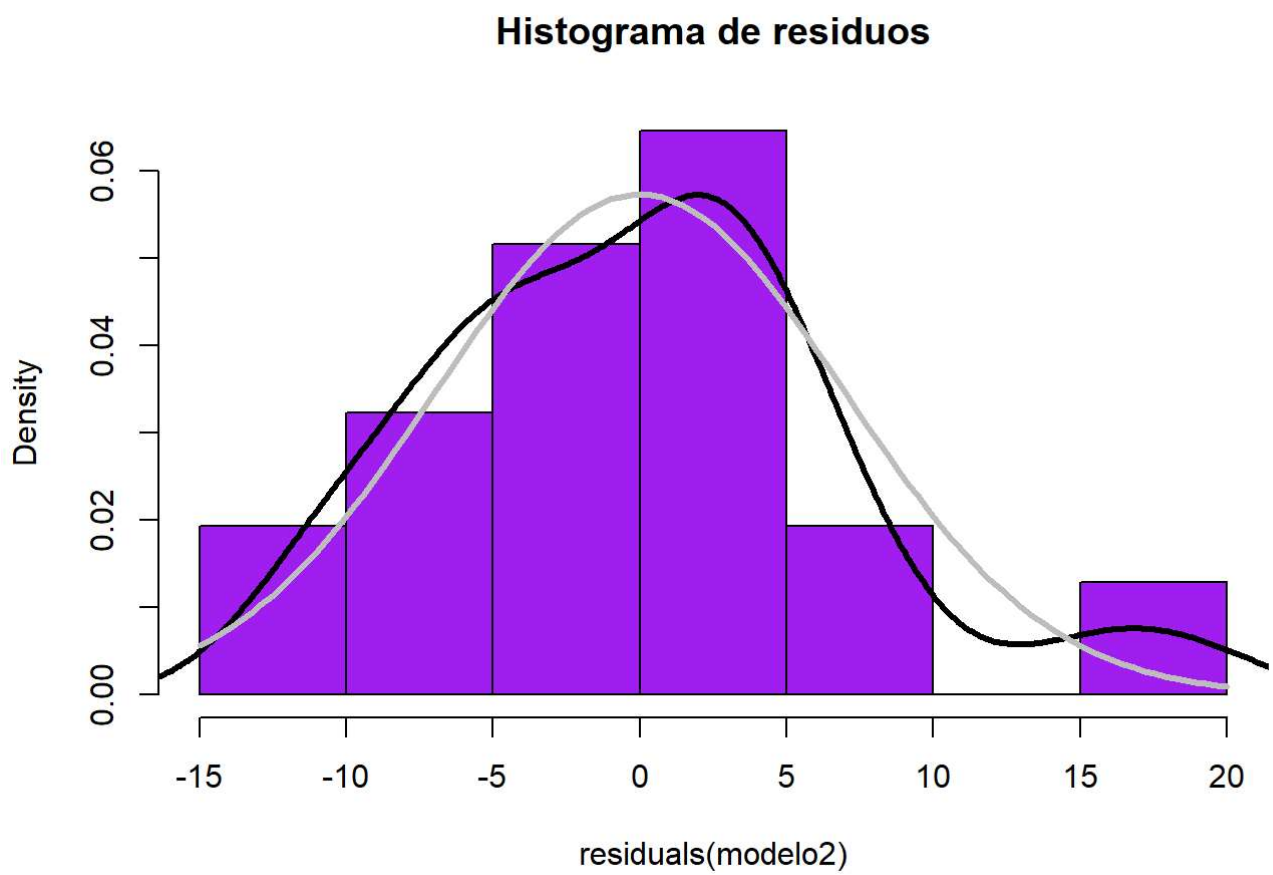


```
# QQ-NORM
qqPlot(residuals(modelo2), pch = 20, col = "black", lwd = 2)
```

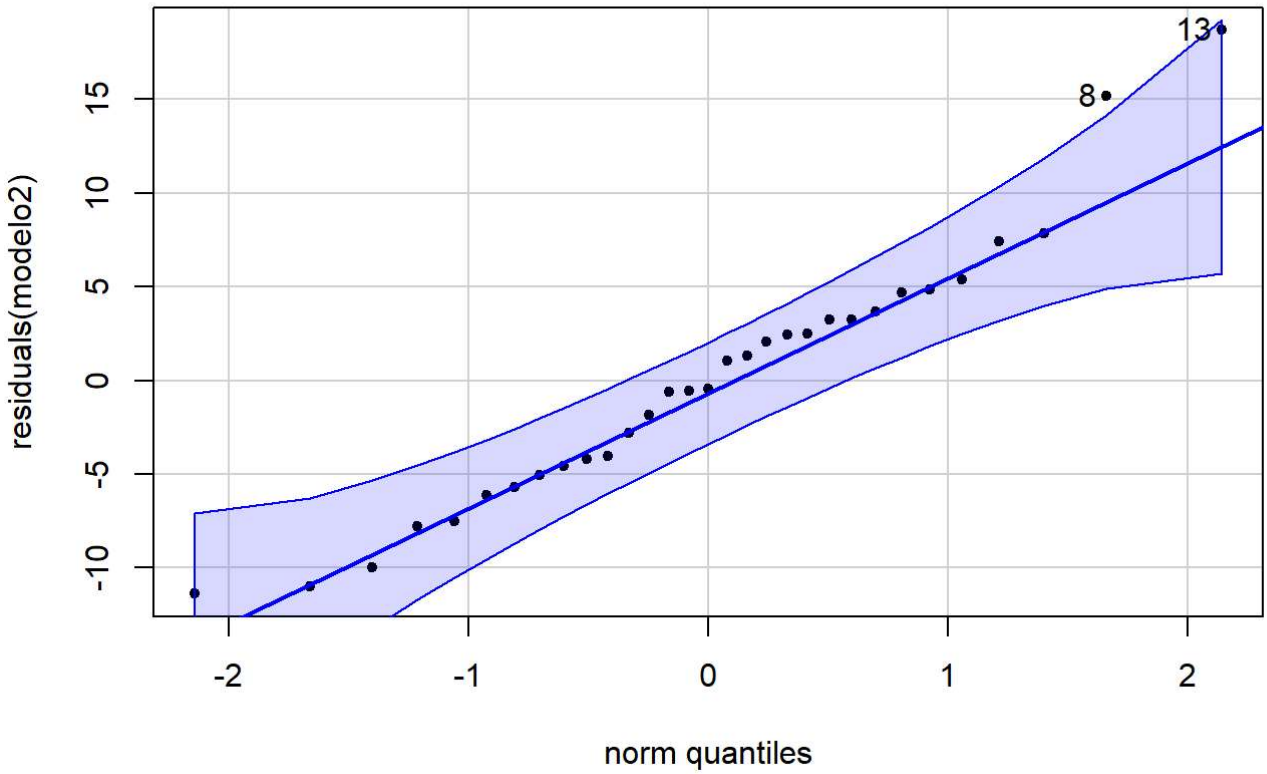


```
## [1] 13  8
```

```
# test de normalidad
shapiro.test(residuals(modelo2)) # Si hay normalidad en los residuales.
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(modelo2)
## W = 0.96041, p-value = 0.2991
```

- Como p-value = 0.2991 > 0.05 no se rechaza la hipótesis nula.
- Existe suficiente evidencia estadística para sustentar la aseveración de que los residuales siguen una distribución significativamente normal.

Homocedasticida (Igualdad de varianzas): La igualdad de varianzas se espera entre los residuos y los valores ajustados del modelo.

```
plot(fitted(modelo2), residuals(modelo2), col = 'grey', pch = 16, main = 'Fitted vs Residuals')
abline(h=0, col='purple')
```

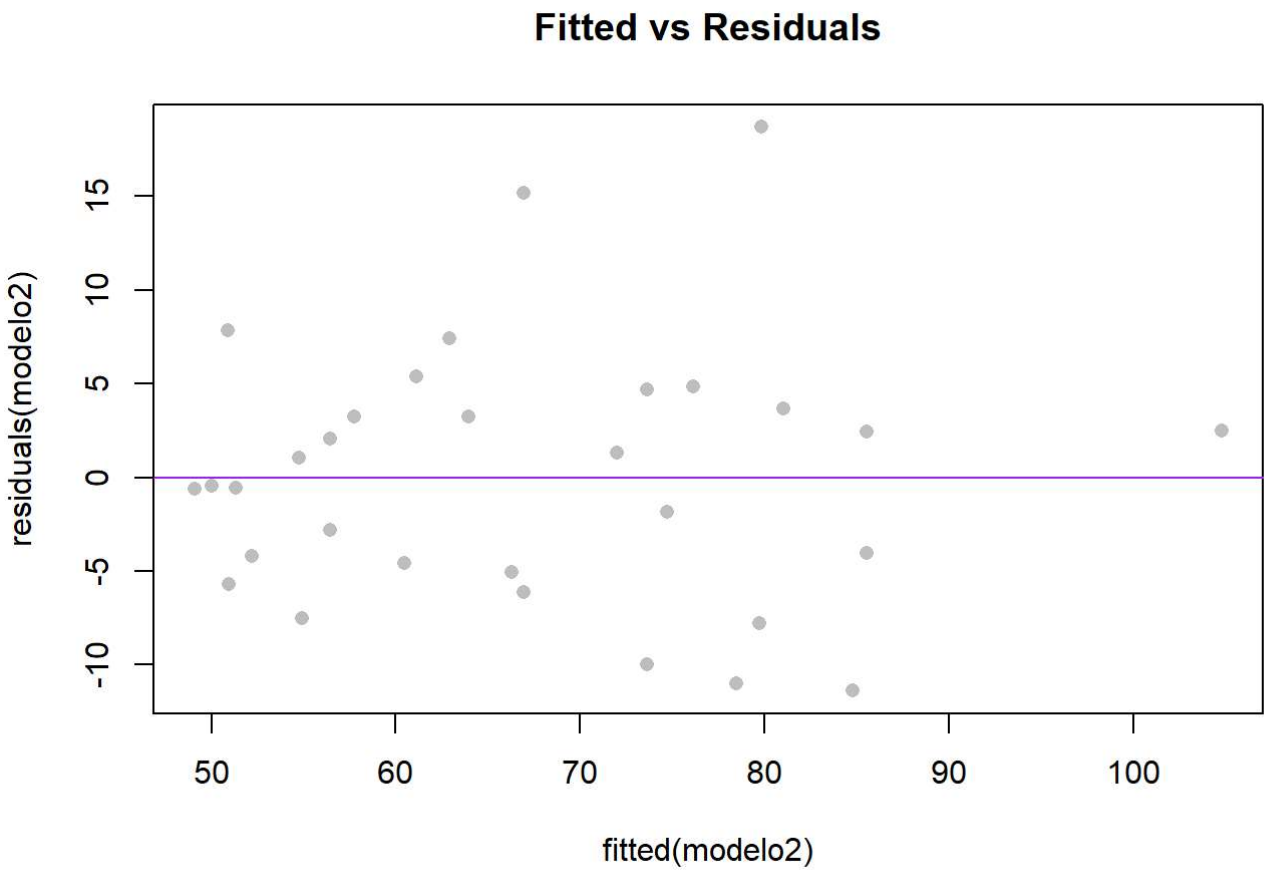

- Como los puntos están dispersos de forma aleatoria arriba y abajo de la línea roja y no hay patrones se sugiere que si hay homocedasticidad.

La Prueba de **Breusch-Pagan** H_0 : La varianza de los errores es constante (homocedasticidad) H_1 : La varianza de los errores no es constante (heterocedasticidad)

```
bptest(modelo2)
```

```
##
##  studentized Breusch-Pagan test
##
## data:  modelo2
## BP = 1.719, df = 1, p-value = 0.1898
```

- Como p-value = 0.1898 > 0.05 no se rechaza la hipótesis nula.
- Existe suficiente evidencia estadística para sustentar la aseveración de que la varianza de los errores es constante.

El test de **Jarque Bera** H_0 : Los residuos siguen una distribución normal (sin sesgo ni curtosis excesiva) H_1 : Los residuos no siguen una distribución normal (pueden tener sesgo y curtosis fuera de los parámetros normales)

```
jarque.bera.test(residuals(modelo2))
```

```
##
##  Jarque Bera Test
##
## data:  residuals(modelo2)
## X-squared = 2.1051, df = 2, p-value = 0.3491
```

- Como p-value = 0.3491 > 0.05 no se rechaza la hipótesis nula,
- Existe suficiente evidencia estadística para sustentar la aseveración de que los residuos siguen una distribución normal.

La prueba de **Durbin-Watson**

- DW ≈ 2 → No hay autocorrelación
- DW < 2 → Autocorrelación positiva
- DW > 2 → Autocorrelación negativa

```
dwtest(modelo2)
```

```
##
##  Durbin-Watson test
##
## data:  modelo2
## DW = 2.1106, p-value = 0.6448
## alternative hypothesis: true autocorrelation is greater than 0
```

- Como DW = 2.1106 lo cual está muy cerca de 2, entonces no hay evidencia de autocorrelación significativa. Esto indica que los errores del modelo son independientes.

```
# Predicciones en el conjunto de prueba
test2 <- test[,c(1:5)]
predicciones2 <- predict(modelo2, newdata = test2, interval = "confidence", level = 0.95)

# Guardar las predicciones y los intervalos de confianza en el conjunto de prueba
test2$predicted <- predicciones2[,1]
test2$lower <- predicciones2[,2]
test2$upper <- predicciones2[,3]

# Ver el conjunto de prueba con las nuevas columnas de predicciones
test2
```

```
## # A tibble: 8 × 8
##    Edad Estatura  Peso Cintura Pulso predicted lower upper
##   <dbl>    <dbl> <dbl>   <dbl> <dbl>     <dbl> <dbl> <dbl>
## 1    17     1.63  51.7    67.2    76      49.6  45.3  53.8
## 2    25     1.52  50.3    73.6    80      55.6  52.1  59.0
## 3    55     1.58  72      93      60      73.8  70.9  76.7
## 4    27     1.51  57.2    82.6    72      64.0  61.4  66.7
## 5    40     1.49  42.4    67.8    80      50.1  45.9  54.3
## 6    22     1.54  55.9    75.5    64      57.4  54.1  60.6
## 7    29     1.62  55.4    75.4    68      57.3  54.0  60.5
## 8    23     1.64  49      74.5    72      56.4  53.1  59.8
```